Московский государственный технический университет им. Н.Э. Баумана Кафедра «Системы обработки информации и управления»



Лабораторная работа №7 по дисциплине «Методы машинного обучения» на тему

 $\langle RL_TD \rangle$

Выполнил: студент группы ИУ5и-24М Аунг Пьио Нанда

1. Цель лабораторной работы

Ознакомление с базовыми методами обучения с подкреплением на основе временных различий.

2. Задание

На основе рассмотренного на лекции примера реализуйте следующие алгоритмы:

- -SARSA
- -Q-обучение
- -Двойное Q-обучение

для любой среды обучения с подкреплением (кроме рассмотренной на лекции среды Toy Text / Frozen Lake) из библиотеки Gym (или аналогичной библиотеки).

3. Ход выполнения работы

Импорт необходимых библиотек

```
Pipi install gym numpy matplotlib

Requirement already satisfied: gym in /usr/local/lib/python3.18/dist-packages (0.25.2)
Requirement already satisfied: numpy in /usr/local/lib/python3.18/dist-packages (1.25.2)
Requirement already satisfied: numpy in /usr/local/lib/python3.18/dist-packages (3.7.1)
Requirement already satisfied: cloudpickle>1.2.0 in /usr/local/lib/python3.10/dist-packages (from gym) (2.2.1)
Requirement already satisfied: contourpy>=1.0.1 in /usr/local/lib/python3.10/dist-packages (from gym) (0.0.8)
Requirement already satisfied: contourpy>=1.0.1 in /usr/local/lib/python3.10/dist-packages (from matplotlib) (1.2.1)
Requirement already satisfied: fonttool=>=4.2.0 in /usr/local/lib/python3.10/dist-packages (from matplotlib) (4.32.4)
Requirement already satisfied: policy=>=0.10 in /usr/local/lib/python3.10/dist-packages (from matplotlib) (4.32.4)
Requirement already satisfied: pillon=>=6.2.0 in /usr/local/lib/python3.10/dist-packages (from matplotlib) (9.4.9)
Requirement already satisfied: pillon=>=6.2.0 in /usr/local/lib/python3.10/dist-packages (from matplotlib) (9.4.0)
Requirement already satisfied: python-dateutil>=2.7 in /usr/local/lib/python3.10/dist-packages (from matplotlib) (9.4.0)
Requirement already satisfied: six>=1.5 in /usr/local/lib/python3.10/dist-packages (from matplotlib) (2.8.2)
Requirement already satisfied: six>=1.5 in /usr/local/lib/python3.10/dist-packages (from matplotlib) (2.8.2)
Requirement already satisfied: six>=1.5 in /usr/local/lib/python3.10/dist-packages (from matplotlib) (2.8.2)

[19] import mumpy as np import mumpy as np import matplotlib.pyplot as plt

[10] # Определение среды env = gym.make('CartPole-vi')

[11] # Дискретизация пространства состояний n.bins = (6, 12, 6, 12) # количество бинов для каждого измерения n.bins = (6, 12, 6, 12) # количество бинов для каждого измерения n.bins = (6, 12, 6, 12) # количество бинов для каждого измерения n.bins = (6, 12, 6, 12) # количество бинов для каждого измерения n.bins = (6, 12, 6, 12) # количество бинов для каждого измер
```

Алгоритм SARSA обновляет Q-значения на основе текущего состояния, действия, следующего состояния и следующего действия.

```
def sarsa(env, episodes, alpha, gamma, epsilon, n_bins, lower_bounds, upper_bounds):
        q_table = np.zeros(n_bins + (env.action_space.n,))
    def choose_action(state, epsilon):
            if np.random.random() < epsilon:</pre>
               return env.action space.sample()
               return np.argmax(q_table[state])
        for episode in range(episodes):
            state = discretize_state(env.reset(), n_bins, lower_bounds, upper_bounds)
            action = choose_action(state, epsilon)
           done = False
           while not done:
                next_state_raw, reward, done, _ = env.step(action)
                next_state = discretize_state(next_state_raw, n_bins, lower_bounds, upper_bounds)
                next action = choose action(next state, epsilon)
                q_table[state + (action,)] += alpha * (reward + gamma * q_table[next_state + (next_action,)] - q_table[state + (action,)])
                state = next_state
               action = next action
        return q_table
```

Q-обучение обновляет Q-значения на основе текущего состояния и действия, выбирая максимальное Q-значение для следующего состояния.

```
[14] def q_learning(env, episodes, alpha, gamma, epsilon, n_bins, lower_bounds, upper_bounds):
           q_table = np.zeros(n_bins + (env.action_space.n,))
           def choose_action(state, epsilon):
              if np.random.random() < epsilon:
                  return env.action space.sample()
                  return np.argmax(q_table[state])
           for episode in range(episodes):
               state = discretize_state(env.reset(), n_bins, lower_bounds, upper_bounds)
               done = False
               while not done:
                  action = choose_action(state, epsilon)
                  next_state_raw, reward, done, _ = env.step(action)
                  next_state = discretize_state(next_state_raw, n_bins, lower_bounds, upper_bounds)
                    q\_table[state + (action,)] += alpha * (reward + gamma * np.max(q\_table[next\_state]) - q\_table[state + (action,)]) 
                   state = next state
           return q_table
```

В Двойном Q-обучении используются две Q-таблицы для уменьшения смещения.

```
def double_q_learning(env, episodes, alpha, gamma, epsilon, n_bins, lower_bounds, upper_bounds):
        q_table1 = np.zeros(n_bins + (env.action_space.n,))
        q_table2 = np.zeros(n_bins + (env.action_space.n,))
        def choose action(state, epsilon):
            if np.random.random() < epsilon:
                return env.action_space.sample()
                return np.argmax(q_table1[state] + q_table2[state])
        for episode in range(episodes):
            state = discretize_state(env.reset(), n_bins, lower_bounds, upper_bounds)
            done = False
            while not done:
                action = choose_action(state, epsilon)
                next_state_raw, reward, done, _ = env.step(action)
                next_state = discretize_state(next_state_raw, n_bins, lower_bounds, upper_bounds)
                if np.random.random() < 0.5:
                    best_next_action = np.argmax(q_table1[next_state])
                    q_table1[state + (action,)] += alpha * (reward + gamma * q_table2[next_state + (best_next_action,)] - q_table1[state + (action,)])
                    best_next_action = np.argmax(q_table2[next_state])
                    q_table2[state + (action,)] += alpha * (reward + gamma * q_table1[next_state + (best_next_action,)] - q_table2[state + (action,)])
                state = next state
        return q_table1 + q_table2
```

Пример использования

```
[19] # Параметры обучения
       episodes = 1000
       alpha = 0.1
       gamma = 0.99
       epsilon = 0.1
[20] # Обучение
       q_table_sarsa = sarsa(env, episodes, alpha, gamma, epsilon, n_bins, lower_bounds, upper_bounds)
       q_table_q_learning = q_learning(env, episodes, alpha, gamma, epsilon, n_bins, lower_bounds, upper_bounds)
       q_table_double_q = double_q_learning(env, episodes, alpha, gamma, epsilon, n_bins, lower_bounds, upper_bounds)
🕻 🕞 # Оценка политики
       def evaluate_policy(env, q_table, episodes=100):
           total_rewards = []
           for _ in range(episodes):
               state = discretize_state(env.reset(), n_bins, lower_bounds, upper_bounds)
               done = False
               total_reward = 0
                  action = np.argmax(q_table[state])
                   next_state_raw, reward, done, _ = env.step(action)
                  next_state = discretize_state(next_state_raw, n_bins, lower_bounds, upper_bounds)
                  total_reward += reward
                  state = next_state
               total_rewards.append(total_reward)
           return np.mean(total_rewards)
```

Вывод результатов

```
[ [19] # Параметры обучения
       episodes = 1000
       alpha = 0.1
       gamma = 0.99
       epsilon = 0.1
[ 20] # Обучение
       q_table_sarsa = sarsa(env, episodes, alpha, gamma, epsilon, n_bins, lower_bounds, upper_bounds)
       q_table_q_learning = q_learning(env, episodes, alpha, gamma, epsilon, n_bins, lower_bounds, upper_bounds)
       q_table_double_q = double_q_learning(env, episodes, alpha, gamma, epsilon, n_bins, lower_bounds, upper_bounds)
🕻 🕞 # Оценка политики
       def evaluate_policy(env, q_table, episodes=100):
          total_rewards = []
           for _ in range(episodes):
              state = discretize_state(env.reset(), n_bins, lower_bounds, upper_bounds)
              done = False
              total reward = 0
              while not done:
                 action = np.argmax(q_table[state])
                  next\_state\_raw, \ reward, \ done, \ \_ = env.step(action)
                 next_state = discretize_state(next_state_raw, n_bins, lower_bounds, upper_bounds)
                 total_reward += reward
                  state = next_state
              total_rewards.append(total_reward)
          return np.mean(total_rewards)
 [22] mean reward sarsa = evaluate policy(env, q table sarsa)
       mean_reward_q_learning = evaluate_policy(env, q_table_q_learning)
       mean_reward_double_q = evaluate_policy(env, q_table_double_q)
 [23] print(f"SARSA mean reward: {mean_reward_sarsa}")
```

```
[22] mean_reward_sarsa = evaluate_policy(env, q_table_sarsa)
mean_reward_q_learning = evaluate_policy(env, q_table_q_learning)
mean_reward_double_q = evaluate_policy(env, q_table_double_q)

[23] print(f"SARSA mean reward: {mean_reward_sarsa}")

→ SARSA mean reward: 9.63

[26] print(f"Q-Learning mean reward: {mean_reward_q_learning}")

→ Q-Learning mean reward: 10.85

▶ print(f"Double Q-Learning mean reward: {mean_reward_double_q}")

→ Double Q-Learning mean reward: 10.92
```

SARSA (State-Action-Reward-State-Action):

Это метод временных различий, который использует текущую политику для выбора действий. Обновление Q-значений основывается на действиях, выбранных текущей политикой.

Q-обучение:

Это метод временных различий, который использует наилучшие возможные действия для обновления Q-значений. Использует жадное обновление на основе максимальных Q-значений для следующего состояния.

Двойное Q-обучение:

Использует две отдельные Q-таблицы для уменьшения смещения. Обновляет значения попеременно используя обе Q-таблицы, выбирая максимальные значения из одной и обновляя значения в другой.

Список литературы

[1] Гапанюк Ю. Е. Лабораторная работа «Разведочный анализ данных. Исследование и визуализация данных» [Электронный ресурс] // GitHub. — 2024. — Режим доступа: https://github.com/ugapanyuk/courses current/wiki/LAB MMO RL_TD.